Одна точка на код ЕСР

Как убраны дубли координат в привязке станций к OpenStreetMap (osm2esr) · проект RWS 1520

19 957 строк в osm2esr	**18 269** кодов ЕСР	**1 523** кода с 2–6 точками	**268** конфликтов

Коротко. Дубли не удаляются механически (например, «первая строка» или «среднее»). Для каждого кода все точки-кандидаты получают баллы, выбирается лучшая. Затем проверяется, не лежат ли остальные точки в другом месте. Надёжность выбора выражена классом точности A–E, а все кандидаты с баллами сохраняются для ручной проверки. Главная идея, которая и «побеждает» массив, — **сверка с соседями по коду**: коды ЕСР выдаются по участкам подряд, поэтому близкие номера почти всегда географически рядом.

1. Исходные данные и в чём проблема

Справочник ЕСР (`esr.csv`) уникален: 26 644 кода, каждый один раз. Дубли — в файле привязки к OSM (`osm2esr.csv`): 19 957 строк на 18 269 кодов.

- У 1 523 кодов от 2 до 6 точек-кандидатов. Обычно это пассажирский и грузовой парки, платформа или контур одной станции, но иногда ошибочная привязка к одноимённой станции в другом регионе (в худшем случае — за 2 400 км).
- 275 объектов OSM привязаны сразу к нескольким кодам.
- 594 привязки не подтверждены (status = 2).

2. Баллы каждому кандидату

Каждая точка-кандидат получает сумму баллов по признакам:

Признак	Вес
Привязка подтверждена (`status = 1`)	+2,0
Код ЕСР прописан в теге самого объекта OSM	+1,5
Похожесть названия OSM на название ЕСР (0–100 %)	до +3,0
Тип совпадает: остановочный пункт ↔ `halt`, станция ↔ `station`	+0,5
Объект OSM — точка, а не контур	+0,5
Объект OSM привязан ещё к другим кодам	−1,5
Точка далеко от соседей по коду (см. п. 3)	до −4,5

Сравнение названий. Названия приводятся к единому виду: нижний регистр, «ё» → «е», без скобок и служебных слов («о.п.», «платформа», «рзд», «блок-пост» и т. п.). Затем нечёткое сравнение (`rapidfuzz`) со всеми вариантами имени в OSM: основным, альтернативным, старым и официальным. Два дополнительных правила:

- «Петрозаводск» и «Петрозаводск-Пассажирский» — совпадение (одно название начинается с другого, не короче 5 букв);
- «158 км» и «138 км» — несовпадение (разные числа в названиях, похожесть не выше 40 %).

3. Сверка с соседями по коду — главная идея

Сначала отбираются **якоря** — коды, в которых нет сомнений:

- все их кандидаты лежат в пределах 5 км;

- название совпадает на 85 % и больше;
- привязка подтверждена.

Для каждого кандидата берутся 6 ближайших по номеру якорей с теми же первыми двумя цифрами кода (это та же дорога/отделение), и измеряется расстояние до ближайшего из них. До 30 км штрафа нет, дальше он растёт на 1,5 балла за каждые 100 км (максимум −4,5). Так отсеиваются точки, ошибочно привязанные к одноимённой станции в другом конце страны: название у них совпадает идеально, но рядом нет ни одного «соседа по номеру».

4. Выбор точки: одно место или конфликт

Для кода берётся кандидат с наибольшим баллом. Затем кандидаты объединяются в группы: всё, что ближе 5 км друг к другу, — одна станция (парк, платформа, контур).

- У **1 255** из 1 523 кодов все точки — одно место. Противоречия нет, просто берётся лучшая точка.
- У **268** кодов кандидаты в разных местах (медианный разброс — около 100 км). Это настоящий конфликт: выбор считается надёжным, только если лучший кандидат опережает ближайшего «дальнего» соперника на 1,5 балла и больше.

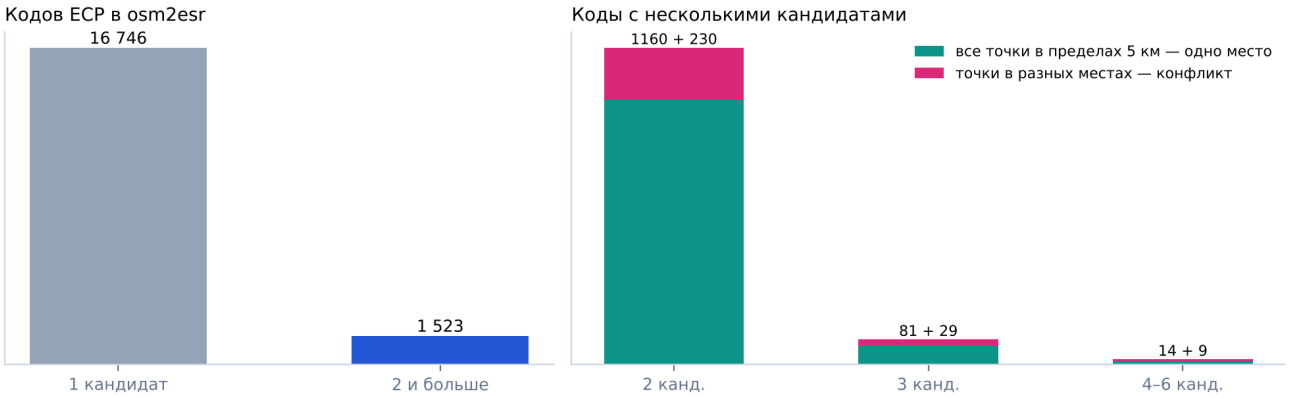


Рис. 1. Сколько кандидатов у кода и сколько из них — настоящие конфликты (числа на столбцах: одно место + разные места).

5. Класс точности — итог выбора

Для выбранной точки проверяются три условия: привязка подтверждена; название похоже (≥ 70 %); ближайший сосед по коду не дальше 50 км.

Ситуация	Класс
Одно место, выполнены все 3 условия	**A** — подтверждено
Одно место, 2 условия	**B** — вероятно
Одно место, меньше 2 условий	**C** — сомнительно
Разные места, все 3 условия и отрыв ≥ 1,5 балла	**B** — вероятно
Разные места, остальные случаи	**C** — сомнительно

Причина сомнения записывается в поле `coord_note` человеческим языком, например: «2 разных места в OSM, разброс 140 км» или «название в OSM отличается (…)».

Результат по 18 269 кодам из osm2esr: A — 17 387, B — 738, C — 62; ещё 82 кода позже переставлены по тарифным участкам ТР №4 (п. 7). Из 268 конфликтов: 210 → B, 34 → C, 24 → пересчитаны по ТР №4.

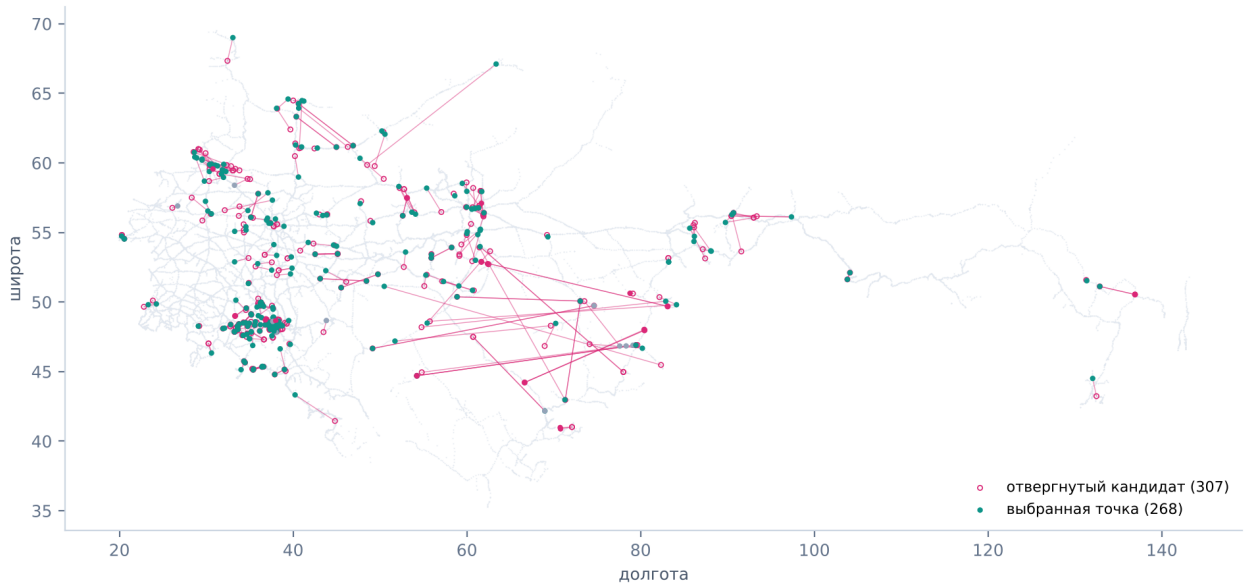


Рис. 2. 268 конфликтных кодов: выбранная точка (цвет — класс) и отвергнутые кандидаты дальше 5 км (розовые кольца, линия — «скачок» до выбранной точки). Длинные линии — привязки к одноимённым станциям в других регионах.

6. Коды-дубли одной станции (dup_esr)

В справочнике ЕСР 1 998 кодов указывают на свой «основной код» (поле `dup_esr`). Цепочки связей собираются в группы (алгоритм union-find: A → B → C — одна группа).

- Если у кода нет своей точки, он получает координаты лучшего кода своей группы с классом **D** и точностью ±3 км.
- Сами такие коды не удаляются: они встречаются в отчётах (дислокации вагонов и т. п.) и должны находиться поиском. Связь видна в поле «Основной код станции».

7. Контроль по тарифному руководству ТР №4

После выбора точки сверяются с ТР №4 (книга 1 — тарифные участки с километражем, книга 2 — транзитные пункты):

- расстояние между соседними станциями участка по прямой не может заметно превышать тарифное расстояние;
- расстояние до ближайшего транзитного пункта сверяется с указанным в ТР №4.

Если точка не сходится с километражем, класс понижается до C, а при явной ошибке координата пересчитывается по участку (интерполяция по километражу между надёжными станциями).

8. Что посмотреть в результатах

Файл / поле	Что там
`data/output/osm_candidates.csv`	Все 19 957 кандидатов: баллы по каждому признаку, отметка «выбран», расстояние до выбранной точки.
`stations.csv`: `osm_candidates, osm_places, osm_spread_km`	Сколько кандидатов и разных мест было у кода, их разброс.
`choice_margin`	Отрыв выбранного кандидата от лучшего «дальнего» соперника (в баллах).
`coord_quality, coord_note`	Класс точности и причина сомнения.

`scripts/build_stations.py`	Код метода: `score_candidates` и `choose`; пороги — константы в начале файла.

Пороги (подобраны на этих данных, легко менять): одно место — 5 км; сосед по коду правдоподобен — до 50 км; похожее название — от 70 %; якорь — от 85 %; отрыв в конфликте — 1,5 балла.

9. Сверка со свежим OpenStreetMap и Викиданными

После сборки каждая точка сверяется с двумя независимыми источниками, выгруженными 24.10.2026: свежим OpenStreetMap (17 764 объектов с тегом `esr:user`, Overpass API) и Викиданными (14 207 станций с кодом ЕСР, свойство P2815). Старый файл `osm2esr.csv` устарел: в нём нет 1 571 кода, которые сейчас есть в OSM.

- **подтверждено** — источник в пределах max(3 км, заявленной точности); оценки C и E при этом уточняются точкой источника (класс B);
- **заменено** — оба источника согласны между собой (≤ 3 км), а точка справочника дальше 5 км (решение большинством);
- **добавлено** — код без координат получает точку источника: оба согласны — A, один с тем же названием — B (названия сравниваются и через транслитерацию: эстонские и литовские станции в источниках записаны латиницей);
- **расхождение** — больше 5 км и не решено большинством: точка не меняется, код выносится в список для ручной проверки (`review_coordinates.csv`).

Класс до сверки	Сверено	Медиана, км	Подтверждено	Заменено	Расхождения
A	16 271	0,01	16 149	14	32
B	594	0,0	575	4	8
C	43	0,09	26	3	14
D	274	0,03	249	3	14
E	2 115	1,48	1 737	191	92

Итог: подтверждено 18 736 точек (из них 1 589 приблизительных оценок уточнено), заменено 215, координаты получили 277 кодов — без координат осталось 786 вместо 1 063; на ручную проверку — 213. Медиана расхождения у класса A — 0,01 км: выбор точки из дублей (п. 2–5) подтверждается независимыми источниками.

Поиск по названию. Коды, оставшиеся без координат, ищутся по названию среди всех станций и платформ OSM (41 тыс. объектов, с транслитерацией): точка должна быть в своём регионе и согласовываться с тарифным расстоянием до соседа по участку ТР №4. Так найдено ещё 108 кодов (64 подтверждены участком, 44 — только регионом, класс C). Яндекс Карты не используются: условия их API запрещают сохранять координаты.

Итоговая карта

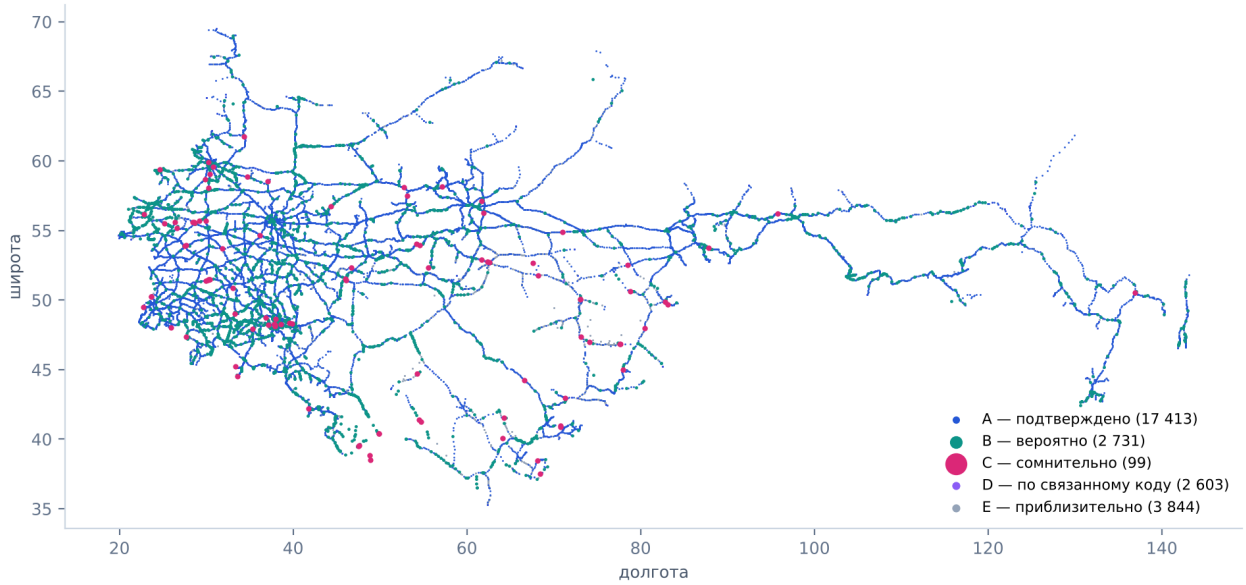


Рис. 3. Все станции справочника с координатами, цвет — класс точности. Класс E — приблизительные оценки для кодов, которых нет в OSM (по участкам ТР №4 и соседям по коду), D — по связанному коду.